자연어처리 입문 중간고사 모의시험 A

문제지 | 7문항 · 100점 · 권장 시간 50분

이름 _____ 시작 _____ 종료 _____

작년 복기본의 유형을 바탕으로 새 문장과 수치를 사용했습니다. 실제 시험의 시간·배점을 재현한 것은 아닙니다. 별도 지시가 없으면 풀이를 적고, 분수로 답해도 됩니다.

1. 정규표현식 적용

15점

다음 문장에서 각 패턴의 **모든 비중첩 매칭 결과**를 왼쪽부터 순서대로 적으세요. 대소문자를 구분하며 Python 정규표현식의 기본 동작을 따릅니다. 같은 결과가 반복되면 각각 적으세요.

The cats saw a cat, then 12 dogs and 003 birds. The cat slept.

소문항	패턴 또는 작업	답
(1) 3점	[tT]he	The, then
(2) 3점	\b[tT]he\b	The
(3) 3점	\d+	12, 003
(4) 3점	cat(?=s)	cat

(5) 패턴 **(\d+)**의 모든 매칭을 **<\1>**로 치환한 문장 전체를 적으세요. \1은 첫 번째 캡처 그룹입니다. (3점)

~, then 12 dogs and 12 birds. ~

2. BPE를 2회 수행하기

15점

문자 단위에서 시작하여 가장 빈번한 인접 토큰 쌍을 한 번씩 병합합니다. 단어 빈도를 반영하고, 선택한 쌍은 모든 단어에 적용합니다. 단어 경계를 넘는 쌍과 별도 끝 기호는 사용하지 않습니다. 매회 빈도를 다시 계산하세요.

단어	빈도	초기 분할
tall	4	t a l l
taller	2	t a l l e r
talk	3	t a l k
small	1	s m a l l

(1) 각 회차의 선택 쌍과 빈도를 적으세요. (회차당 4점, 총 8점)

1회: 쌍 _____al_____ 빈도 _4_ 2회: 쌍 _____tal_____ 빈도 _3_

(2) 2회 뒤 각 단어의 분할을 적으세요. (4점)

tall: tal, l___ taller: tal, l, e, r talk: tal, k small: s, m, al, l

(3) 2회 뒤 누적 vocabulary 전체를 적으세요. 기존 토큰도 포함합니다. (3점)

tal, al, t, a, l, e, r, k, s, m

자연어처리 입문 중간고사 모의시험 A

문제지 | N-gram 언어 모델

3. Bigram 확률 계산

15점

학습 corpus가 다음 네 문장입니다. **MLE bigram 모델**을 사용하며 smoothing은 하지 않습니다. 문장끼리는 이어 붙이지 않습니다. <s>는 시작 조건이고 </s>는 예측할 종료 토큰입니다.

학습 문장
<s> we study nlp </s>
<s> we study math </s>
<s> they study nlp </s>
<s> we like nlp </s>

(1) 다음 조건부확률을 구하세요. 분자와 분모의 count가 보이게 적으세요. (각 2점, 총 8점)

P(we | <s>) = 3/4 P(study | we) = 2/3

P(nlp | study) = 2/3 P(</s> | nlp) = 3/3

(2) 문장 we study nlp의 시작·종료 전이를 포함한 확률을 구하세요. (5점)

$P(w_1|<s>) \cdot P(study|we) \cdot P(nlp|study) \cdot P(</s>|nlp)$

$= 1/3$

(3) 문장 we like math의 확률을 구하고, 그 값이 나오는 이유를 적으세요. (2점)

0 ∵ C(math) = 0 이기 때문이다.

추가 계산 공간

자연어처리 입문 중간고사 모의시험 A

문제지 | Naive Bayes

4. Add-1 Naive Bayes 문서 분류 22점

아래 학습 문서로 multinomial Naive Bayes를 학습합니다. **단어 likelihood에만 add-1 smoothing**을 적용합니다. 모든 단어를 유지하고 대소문자 구분 문제는 없습니다. 전체 학습 vocabulary 밖의 테스트 단어는 무시합니다.

클래스	학습 문서
+	bright fun
+	bright bright story
-	dull slow
-	dull story slow

) bright x3 , fun , story) 5

dull x2 , slow x2 , story) 5

테스트 문서: bright mystery story dull

(1) P(+)와 P(-)를 구하세요. (4점)
(2) 전체 vocabulary V, |V|, 클래스별 token 수 N_+와 N_-를 적으세요. (4점)
(3) bright, story, dull의 클래스별 likelihood 6개를 구하세요. (6점)
(4) 클래스별 비정규화 점수 s(c) = P(c)P(d | c)를 구하세요. (6점)
(5) 최종 클래스를 적으세요. (2점)

(1), (2) 답

(1) $P(+) = 0.5$, $P(-) = 0.5$

(2) $V = \{bright, fun, story, dull, slow\}$

$|V| = 5$, $N_+ = 5$, $N_- = 5$

(3) 단어	P(w | +)	P(w | -)
bright	0.4	0.1
story	0.2	0.2
dull	0.1	0.3

(4), (5) 점수 계산과 최종 답

(4) $S(+) = \frac{1}{2} \times \frac{3+1}{5+5} \times \frac{1+1}{5+5} \times \frac{0+1}{5+5} = 0.004$

$S(-) = \frac{1}{2} \times \frac{0+1}{5+5} \times \frac{1+1}{5+5} \times \frac{2+1}{5+5} = 0.003$

(5) (+)

자연어처리 입문 중간고사 모의시험 A

문제지 | 경사하강법

5. Gradient descent 표 완성 15점

출력이 $y = w_0x_0 + w_1x_1$인 선형 모델입니다. **Bias와 activation은 없습니다.** 다음 조건으로 squared error를 최소화합니다.

항목	값
입력	$x_0 = 2, x_1 = 1$
정답	$y^* = 5$
손실	$L = (y - 5)^2$
학습률	$\eta = 0.05$
초기 가중치	$w_0 = 0, w_1 = 0$

(1) $\partial L/\partial w_0$와 $\partial L/\partial w_1$을 각각 y의 식으로 쓰세요. (3점)

$\frac{\partial L}{\partial w_0} = \frac{\partial L}{\partial y} \cdot \frac{\partial y}{\partial w_0} = 4(y-5)$, $\frac{\partial L}{\partial w_1} = 2(y-5)$

(2) 아래 표를 완성하세요. k는 완료한 업데이트 횟수입니다. 각 행의 y와 L은 **그 행의 가중치**로 구합니다. 한 step에서 두 가중치는 같은 현재 값의 gradient를 사용해 동시에 갱신합니다. (빈칸당 1점, 총 12점)

k	w_0	w_1	y	L
0	0	0	0	25
1	0.05×20 = 1	0.5	2.5	6.25
2	1.5	0.175	3.75	1.5625
3	1.75	0.875	4.375	0.390625

계산 공간

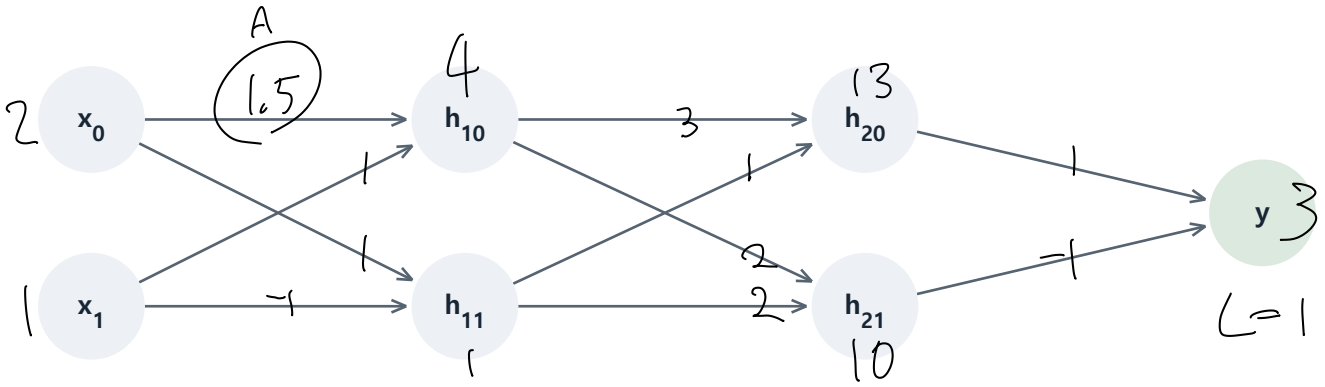
자연어처리 입문 중간고사 모의시험 A

문제지 | 역전파와 다중 분류 손실

6. Backpropagation과 가중치 업데이트

15점

모든 연결은 아래 식으로 정의되며, bias와 activation은 없습니다. 입력은 $x_0 = 2, x_1 = 1$, 학습할 가중치는 $a = 1.5$입니다. 나머지 계수는 고정합니다.



첫 번째 은닉층	두 번째 은닉층	출력과 손실
$h_{10} = ax_0 + x_1$ $h_{11} = x_0 - x_1$	$h_{20} = 3h_{10} + h_{11}$ $h_{21} = 2h_{10} + 2h_{11}$	$y = h_{20} - h_{21}$ $L = (y - 2)^2$

(1) h_{10}, h_{11}, h_{20}, h_{21}, y를 구하세요. (각 1점, 총 5점)

$h_{10}=4,\ h_{11}=1,\ h_{20}=13,\ h_{21}=10,\ y=3$

(2) a에서 y로 가는 두 경로를 반영하여 ∂y/∂a를 구하세요. 경로별 기여를 적으세요. (4점)

$$\frac{\partial y}{\partial a} = \frac{\partial y}{\partial h_{10}} \cdot \frac{\partial h_{10}}{\partial a} = \left(\frac{\partial y}{\partial h_{20}} \cdot \frac{\partial h_{20}}{\partial h_{10}} + \frac{\partial y}{\partial h_{21}} \cdot \frac{\partial h_{21}}{\partial h_{10}}\right)\frac{\partial h_{10}}{\partial a} = (1\times 3 + (-1)\times 2)\times 2 = 2$$

(3) ∂L/∂a를 구하세요. (3점)

$$\frac{\partial L}{\partial a} = \frac{\partial L}{\partial y}\frac{\partial y}{\partial a} = 2(y-2)\cdot 2 = 4$$

(4) η = 0.1이고 a_new = a - η(∂L/∂a)입니다. 갱신된 a_new를 구하세요. (3점)

$$a_{new} = 1.5 - 0.1 \times \frac{\partial L}{\partial a} = 1.5 - 0.4 = 1.1$$

7. 다중 분류 손실함수 빈칸

3점

3-class 분류에서 예측 확률은 p = (0.15, 0.60, 0.25), 정답 one-hot 벡터는 t = (0, 1, 0)입니다. 한 표본의 negative log-likelihood를 완성하세요. log는 자연로그이며, **로그값을 수치로 계산할 필요는 없습니다.**

L = [A] log [B]

A = _____ (1점) B = _____ (2점)