자연어처리 입문 중간고사 모의시험 B

새 문제지 | 8문항 · 120점 · 권장 시간 60분

이름 _____ 시작 _____ 종료 _____

작년 복기본과 같은 7개 유형에 벡터 의미론·임베딩을 더한 새 문제집입니다. 모든 문항은 A형과 다른 문장·데이터를 사용합니다. 분수로 답해도 됩니다. 1~7번은 100점, 8번은 20점입니다.

1. 정규표현식 적용 15점

각 패턴의 모든 비중첩 매칭을 왼쪽부터 적으세요. 대소문자를 구분하고 Python 정규표현식의 기본 동작을 따릅니다. 같은 결과도 출현 횟수대로 적습니다.

The fox saw other foxes, then 24 birds and 007 fish. The fox hid.

소문항	패턴	매칭 결과
(1) 3점	[tT]he	
(2) 3점	\b[tT]he\b	
(3) 3점	\d+	
(4) 3점	fox(?=es)	

(5) 패턴 (\d+)의 모든 매칭을 [\1]로 치환한 문장 전체를 적으세요. \1은 현재 매칭의 첫 번째 캡처 그룹입니다. (3점)

---

2. BPE를 2회 수행하기 15점

문자 단위에서 시작합니다. 단어 빈도를 반영하여 가장 빈번한 인접 쌍을 선택하고, 해당 쌍을 모든 단어에 병합합니다. 매회 빈도를 다시 세세요. 단어 경계를 넘는 쌍과 끝 기호는 사용하지 않습니다.

단어	빈도	초기 분할
play	5	p l a y
player	3	p l a y e r
plain	2	p l a i n
clay	4	c l a y

(1) 각 회차의 선택 쌍과 실제 빈도를 쓰세요. (회차당 4점, 총 8점)

1회: 쌍 _____ 빈도 _____ 2회: 쌍 _____ 빈도 _____

(2) 2회 뒤 단어별 분할을 쓰세요. (4점)

play: _____ player: _____ plain: _____ clay: _____

(3) 기존 토큰을 포함한 최종 vocabulary 전체를 쓰세요. (3점)

자연어처리 입문 중간고사 모의시험 B

문제지 | N-gram 언어 모델

3. Bigram 확률 계산 15점

다섯 학습 문장으로 MLE bigram 모델을 만듭니다. Smoothing을 하지 않으며 문장끼리는 이어 붙이지 않습니다. <s>는 시작 조건, </s>는 예측할 종료 토큰입니다.

학습 문장
<s> students read books </s>
<s> students read papers </s>
<s> students write papers </s>
<s> teachers read books </s>
<s> teachers write notes </s>

(1) 다음 조건부확률을 분자·분모의 count가 보이게 적으세요. (각 2점, 총 8점)

P(students | <s>) = _____ P(read | students) = _____
P(books | read) = _____ P(</s> | books) = _____

(2) students read books의 시작·종료 전이를 포함한 문장 확률을 구하세요. (5점)

(3) students write books의 문장 확률과 그 이유를 쓰세요. 어떤 count를 사용하는지 명확히 적으세요. (2점)

추가 계산 공간

자연어처리 입문 중간고사 모의시험 B

문제지 | Naive Bayes

4. Add-1 Naive Bayes 문서 분류 22점

아래 문서로 multinomial Naive Bayes를 학습합니다. 단어 likelihood에만 add-1 smoothing을 적용합니다. Stop word 제거는 하지 않고, 전체 학습 vocabulary 밖의 테스트 단어는 무시합니다.

클래스	학습 문서
+	clear useful
+	clear clear guide
+	useful guide
-	confusing dull
-	dull guide

테스트 문서: clear fresh guide dull

(1) P(+)와 P(-)를 구하세요. (4점)
(2) 전체 vocabulary V, |V|, N_+, N_-를 적으세요. (4점)
(3) clear, guide, dull의 클래스별 likelihood 여섯 개를 구하세요. (6점)
(4) 클래스별 점수 s(c)=P(c)P(d | c)를 구하세요. 정규화는 필요 없습니다. (6점)
(5) 최종 클래스를 적으세요. (2점)

(1), (2) 답

(3) 단어	P(w | +)	P(w | -)
clear		
guide		
dull		

(4), (5) 계산과 최종 답

자연어처리 입문 중간고사 모의시험 B

문제지 | 경사하강법

5. Gradient descent 표 완성 15점

선형 모델 $y=w_0x_0+w_1x_1$의 squared error를 최소화합니다. Bias와 activation은 없습니다.

항목	값
입력	$x_0=1$, $x_1=3$
정답	$y^*=8$
손실	$L=(y-8)^2$
학습률	$\eta=0.025$
초기 가중치	$w_0=0$, $w_1=0$

(1) $\partial L/\partial w_0$와 $\partial L/\partial w_1$을 y의 식으로 쓰세요. (3점)

(2) 표를 완성하세요. k는 완료한 업데이트 횟수입니다. 각 행의 y와 L은 그 행의 가중치로 계산합니다. 두 가중치는 같은 현재 파라미터에서 구한 gradient로 동시에 갱신합니다. (빈칸당 1점, 총 12점)

k	w_0	w_1	y	L
0	0	0	0	64
1				
2				
3				

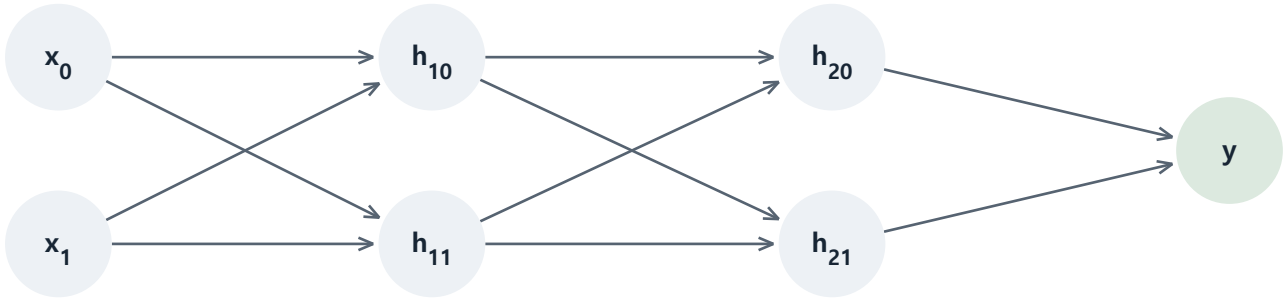
계산 공간

자연어처리 입문 중간고사 모의시험 B

문제지 | 역전파와 다중 분류 손실

6. Backpropagation과 가중치 업데이트 15점

입력 $x_0=3$, $x_1=1$, 학습할 가중치 a=1입니다. 나머지 계수는 고정하고, bias와 activation은 없습니다. 연결과 계산은 아래 식으로 정의합니다.



첫 번째 은닉층	두 번째 은닉층	출력과 손실
$h_{10}=ax_0+2x_1$ $h_{11}=x_0+x_1$	$h_{20}=2h_{10}+h_{11}$ $h_{21}=h_{10}-2h_{11}$	$y=2h_{20}+h_{21}$ $L=(y-24)^2$

(1) h_{10}, h_{11}, h_{20}, h_{21}, y를 구하세요. (각 1점, 총 5점)

(2) a에서 y까지 두 경로의 기여를 적고 $\partial y/\partial a$를 구하세요. (4점)

(3) $\partial L/\partial a$를 구하세요. (3점)

(4) η=0.01입니다. a_new=a-η($\partial L/\partial a$)로 갱신한 a_new를 구하세요. (3점)

7. 다중 분류 손실함수 빈칸 3점

예측 확률 p=(0.20, 0.10, 0.70), 정답 one-hot 벡터 t=(1, 0, 0)입니다. 한 표본의 NLL을 완성하세요. log는 자연로그이며 로그값을 수치로 계산할 필요는 없습니다.

L = [A] log [B]

A = _____ (1점) B = _____ (2점)

자연어처리 입문 중간고사 모의시험 B

문제지 | Vector semantics and embeddings | 권장 시간 10분

8. 벡터 의미론과 임베딩 20점

(1) 의미 관계 (4점) 다음 두 쌍이 similarity와 relatedness 중 어느 관계를 더 직접적으로 보여주는지 쓰고, 두 관계의 차이를 한 문장으로 설명하세요. 분류 각 1점, 설명 2점입니다.

단어 쌍	관계
car / bicycle	
car / road	

(2) Cosine similarity (4점) u=(2, 1, 2), v=(1, 2, 2)입니다. 코사인 유사도의 식을 쓰고 내적, 각 벡터의 길이, 최종 값을 구하세요. 분수로 답해도 됩니다.

(3) TF-IDF (4점) 전체 문서 수 D=10000, df_t=100, C(t,d)=100입니다. $tf=1+\log_{10} C(t,d)$, $idf=\log_{10}(D/df_t)$를 사용합니다. tf, idf, TF-IDF를 구하세요. 같은 문서에서 t가 여러 번 나올 때 df에 몇 번 기여하는지도 적으세요.
tf = _____ idf = _____ TF-IDF = _____ df 기여 = _____

(4) PMI (4점) P(w)=0.2, P(c)=0.2, P(w,c)=0.02입니다. 로그 밑은 2입니다. PMI의 식, 독립일 때 예상되는 동시출현 확률, PMI 값을 쓰고 부호를 해석하세요.

(5) Word2vec (4점) 문장 we enjoy [fresh] fruit daily에서 fresh가 중심 단어이고 window는 좌우 한 칸입니다. Skip-gram의 positive pair 두 개를 쓰세요. Negative sampling을 쓰는 이유를 한 문장으로 쓰고, 표준 Word2vec이 static / contextual 중 무엇인지 고르세요.